


6週間で構築した長期記憶を持つ音声AIチューターの全貌

高額な人間の講師と、毎回記憶をリセットされる汎用AI。このギャップを埋めるため、
GMAT特化型の音声AIチューター「SamiWISE」を開発した。
本資料は、マルチエージェント・ルーティング、構造化メモリー、そしてエッジインフラの限界を紐解く、
2026年のAIプロダクト開発における実践的なシステム解剖録である。



{ Next.js } { Claude Sonnet } { Groq } { Supabase } { Railway }

GMAT学習市場における「コスト」と「連続性」のジレンマ

人間のプロ講師



\$150-200/時間

3ヶ月で\$5,000-\$10,000

高額すぎて一部の学習者しかアクセスできない。

既存のAIチューター



記憶喪失のシステム

毎回ゼロから説明が必要

セッションごとに弱点を説明する必要があり、学習のコンテキストが引き継がれない。

SamiWISE




24時間利用可能

月額\$49

過去の全セッションを記憶し、弱点に基づいた個別指導を低コストで実現。

唯一の差別化要因：音声対話 (Voice) + 長期記憶 (Memory) + 公式レベルの教材 (Real GMAT Content) の統合


フルスタックAI・トポロジーマップ



総レイテンシ：5～8秒

完璧ではないが、人間の講師が思考する際の
間（ま）として自然に機能する設計。サー
バーレスの制限を回避するため、コア機能は
Railwayの常時稼働コンテナに配置。

見えないオーケストレーター：マルチエージェント・ルーティング




ユーザーには「Sam」という単一の人格に見える。しかし裏側では、超高速なルーターが発言意図を解析し、最適な専門家モデルへ処理を透過的にハンドオフしている。単一の巨大なプロンプトよりも、専門特化したプロンプトを持つ複数エージェントの方が、回答精度が劇的に向上する。

速度と推論の分離: モデル選定のトレードオフ


	オーケストレーター (ルーター)	スペシャリスト (講師)
LLM / API	Groq (Llama-3.3-70b)	Claude Sonnet
最適化の目的	圧倒的なスピード (Routing speed)	深い推論能力 (Deep reasoning)
処理時間	~200ms	3~5秒
出力形式	構造化JSONによる転送先指定 []	ユーザーへの直接的な指導発話

すべての処理をClaudeで実行するとルーティングだけで数秒をロスする。判断ロジックはGroqに任せ、高度な説明のみをClaudeに担当させることで、UXとコストの最適なバランスを実現した。

長期記憶のジレンマ：量より質への転換



初期アプローチ。全会話履歴を保存して直接プロンプトに注入。ノイズが増大し、過去の無関係な情報に引きずられてパフォーマンスが急降下した。



改善後。セッション終了後にバックグラウンドでMemory Agentが起動。会話から「学習者の特徴」のみを抽出し、構造化データとして保存する。

記憶の設計図：Supabase上の構造化プロフィール


```
learner_profile.json

{
  "learner_profile": {
    "weak_topics": ["inequalities", "probability in DS"],
    "effective_techniques": ["visual analogies", "step-by-step breakdown"],
    "common_error_patterns": ["rushing data sufficiency statements"],
    "trajectory": "improving on verbal, needs pacing strategy"
  }
}
```

セッション開始時、このJSONデータのみをスペシャリストのシステムプロンプトに注入する。


ユーザーが説明しなくても、AIが「先週はDSの確率問題で苦戦しましたね。今回は別のアプローチで解いてみましょう」と自発的に提案可能になる。

知識のサプライチェーン：無料データセットからプレミアムな教育へ



オープンソースのデータセット（特にaqua_rat）の品質は想像以上に高い。これらを適切にRAGパイプラインに組み込むことで、高額な有料コースを凌駕する演習量を提供できる。

間隔反復 (FSRS) : Ankiアルゴリズムによる弱点克服



単なる音声チューターではなく、ビジュアルな演習モードを実装。解答の正誤、所要時間、難易度を記録し、忘却曲線に基づき最適な復習タイミングを自動スケジューリングする。

ユーザーは管理の手間なく、弱点のみに集中できる。副次効果として、学習ジャーナルと「連続学習日数 (Streak)」の記録が、Duolingoと同等の心理的リテンション効果を生む。

インフラの境界線：VercelとRailwayの分割

[Vercel]	[Railway]
サーバーレス・ファンクション	永続的コンテナ
最大800秒でタイムアウト (致命的)	無制限 (No limits)
発生する	発生しない (常にウォーム状態)
Next.js UI / 認証 / ルーティング	マルチエージェントの実行 / 音声セッション処理

教訓：インフラの分割は早期に行うべき。AIとの30分間の音声チュータリングセッションをVercel上で実行しようとする、タイムアウトにより確実に行き詰まる。重いエージェント処理には、Railwayの永続コンテナが必須であった。

構築の現実：完了したアーキテクチャと未解決の課題

構築と検証完了

- ✓ マルチエージェント・ルーティングの応答精度
- ✓ SupabaseでのMemory Agentによるプロフィール抽出
- ✓ Next.jsのUIとFSRSによる演習キュー
- ✓ Paddleによる決済基盤（米国50州の売上税とチャージバックを自動処理）

未解決・検証待ち

- ⚠ 音声パイプライン
（Deepgram/ElevenLabsの設定は完了したが、本番テスト未了）
- ⚠ RAGのインデックス化（スクリプト準備済みだがデータ投入待ち）
- ⚠ 実際のユーザーデータ（現時点でフィードバックはゼロ）


過剰な宣伝は技術者の信頼を損なう。アーキテクチャは完成したが、本当の検証はこれから実際のユーザーを迎え入れてから始まる。

継続性のアーキテクチャ (The Architecture of Continuity)

優れたAIプロダクト (Next-Gen AI Products)


特化型ルーティング

{巨大な汎用モデルへの依存からの脱却。}



構造化された状態管理

{生データの蓄積ではなく、コンテキストの精製。}



非同期のインフラ

{実行時間の制約に縛られないアーキテクチャ。}



次世代のAIプロダクトは、単に「より賢いベースモデル」を使うことで勝つのではない。
専門化されたタスクに対する『優れたルーティング』と『状態（記憶）の管理』を構築できた者が勝つ。